- ✓ 3.6 EXERCISES/Myatt

Άσκηση 1:

1. Name: Discrete
2. Age: Discrete
3. Gender: Dichotomous
4. Blood group: Discrete
5. Weight (kg): Discrete
6. Height (m): Continuous
7. Systolic Blood Pressure: Discrete
8. Diastolic Blood Pressure: Discrete
9. Temperature (F): Continuous
10. Diabetes : Binary

Άσκηση 2:

1. Name: Nominal
2. Age: Ratio
3. Gender: Nominal
4. Blood group: Nominal
5. Weight (kg): Ratio
6. Height (m): Ratio
7. Systolic Blood Pressure: Ratio
8. Diastolic Blood Pressure: Ratio
9. Temperature (F): Interval
10. Diabetes : Nominal

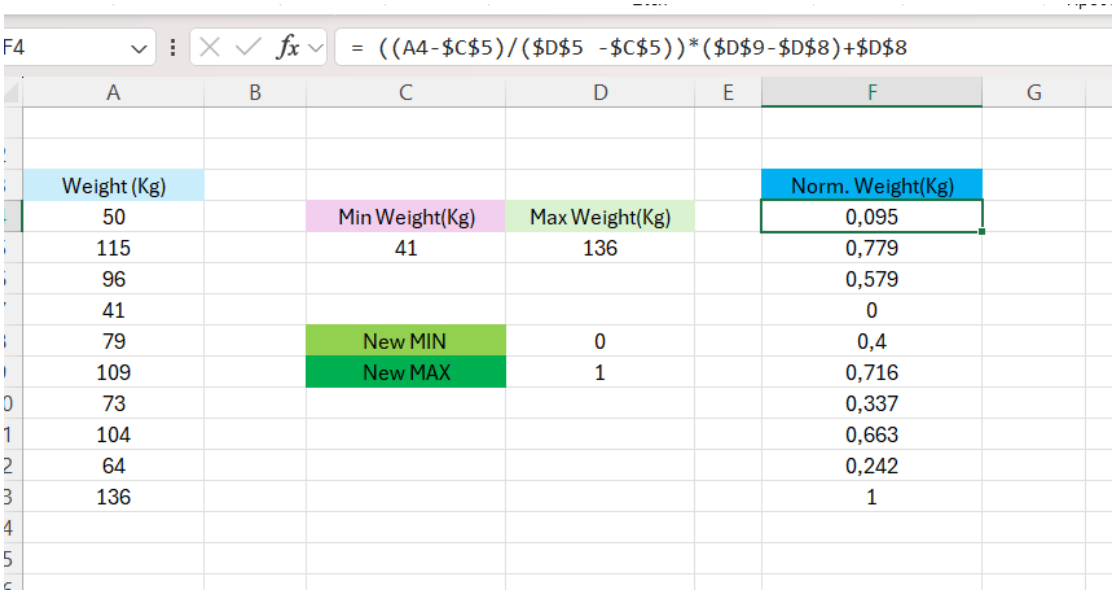
Άσκηση 3:

Για να απαντήσουμε σε αυτό το ερώτημα, κοιτάμε τις στήλες του πίνακα 3.9. Αρχικά, με βάση τα συγκεκριμένα δεδομένα ως αναγνωριστικό κάθε εγγραφής (label) είναι η μεταβλητή/στήλη Name. Ως features (μεταβλητές που χρησιμοποιούνται για την πρόβλεψη του διαβήτη), είναι οι στήλες/μεταβλητές Age, Gender, Blood Group, Weight(kg), Height(m), Systolic Blood Pressure, Diastolic Blood Pressure και Temperature(F). Τέλος, ως response variable, δηλαδή την μεταβλητή που θέλουμε να προβλέψουμε έχουμε την μεταβλητή/στήλη Diabetes.

Άσκηση 4:

Για να το πετύχουμε αυτό πηγαίνουμε στο Excel, για οικονομία χρόνου και χώρου εισήγαγα μόνο την απαραίτητη στήλη με το Βάρος (Weight(Kg)). Εφαρμόζοντας την συνάρτηση MIN και στην συνέχεια MAX, βρίσκω την

μέγιστη και την ελάχιστη εγγραφή του πίνακα και την «αφήνω» σε ένα κελί. Ορίζω καρφωτά το νέο ελάχιστο και το νέο μέγιστο, με ονομασίες New Min, New Max, αντίστοιχα και εφαρμόζω τον τύπο της Min/Max κανονικοποιήσης. Παρακάτω φαίνονται μερικά στιγμιότυπα της διαδικασίας.



F4 | = ((A4-$C$5)/($D$5 -$C$5))*($D$9-$D$8)+$D$8

| | A | B | C | D | E | F | G |
|---|---|---|---|---|---|---|---|
| | | | | | | | |
| | | | | | | | |
| | Weight (Kg) | | | | | Norm. Weight(Kg) | |
| | 50 | | Min Weight(Kg) | Max Weight(Kg) | | 0,095 | |
| | 115 | | 41 | 136 | | 0,779 | |
| | 96 | | | | | 0,579 | |
| | 41 | | | | | 0 | |
| | 79 | | New MIN | 0 | | 0,4 | |
| | 109 | | New MAX | 1 | | 0,716 | |
| | 73 | | | | | 0,337 | |
| | 104 | | | | | 0,663 | |
| | 64 | | | | | 0,242 | |
| | 136 | | | | | 1 | |
| | | | | | | | |
| | | | | | | | |

Στην στήλη Norm.Weight φαίνεται ο νέος πίνακας, καθώς και η συνάρτηση την οποία χρησιμοποίησα για να βγάλω τα αποτελέσματα (στην ουσία ο τύπος της Min/Max Normalization.

Άσκηση 5:

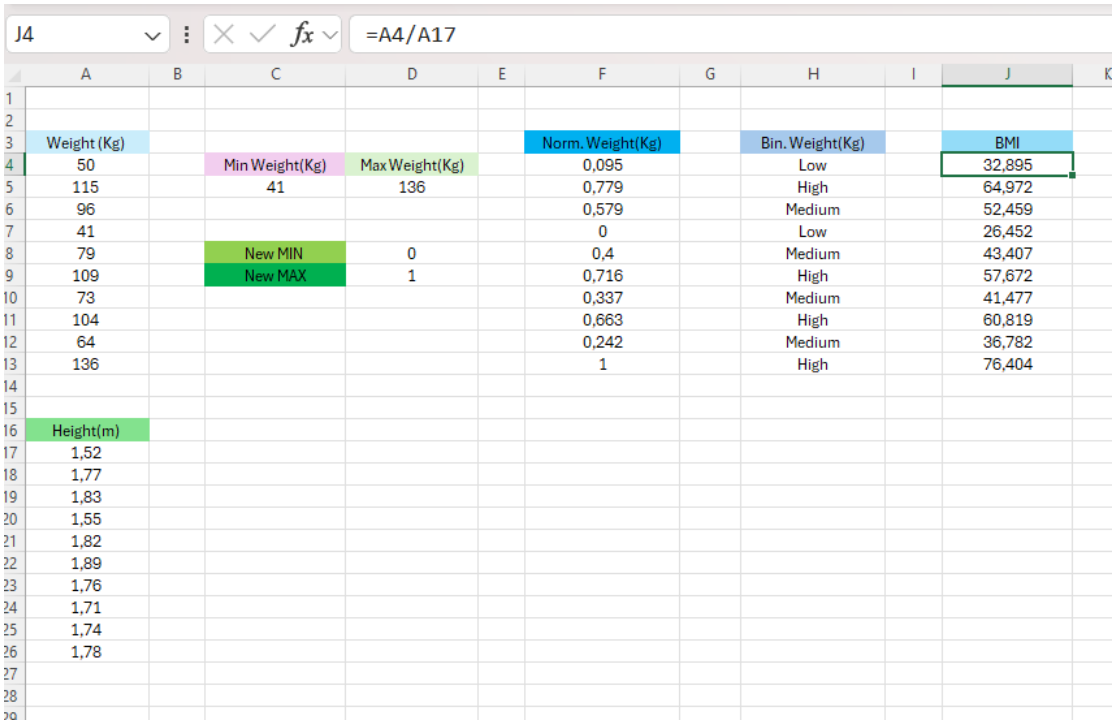
Για την ερώτηση αυτή ακολούθησα παρόμοια διαδικασία.

| | A | B | C | D | E | F | G | H |
|---|---|---|---|---|---|---|---|---|
| | | | | | | | | |
| | | | | | | | | |
| | Weight (Kg) | | | | | Norm. Weight(Kg) | | Bin. Weight(Kg) |
| | 50 | | Min Weight(Kg) | Max Weight(Kg) | | 0,095 | | Low |
| | 115 | | 41 | 136 | | 0,779 | | High |
| | 96 | | | | | 0,579 | | Medium |
| | 41 | | | | | 0 | | Low |
| | 79 | | New MIN | 0 | | 0,4 | | Medium |
| | 109 | | New MAX | 1 | | 0,716 | | High |
| | 73 | | | | | 0,337 | | Medium |
| | 104 | | | | | 0,663 | | High |
| | 64 | | | | | 0,242 | | Medium |
| | 136 | | | | | 1 | | High |
| | | | | | | | | |
| | | | | | | | | |
| | | | | | | | | |

Δημιούργησα μια καινούργια στήλη Bin.Weight(Kg). Η στήλη αυτή δημιουργήθηκε με την συνάρτηση: = *IF(A4<60;"Low"; IF(A4<100;"Medium"; "High"))* για το πρώτο πεδίο και στην συνέχεια σέρνοντας τον κέρσορα παρακάτω για να γεμίσει εξίσου ολόκληρη η στήλη. Έτσι, καταλήξαμε στην νέα στήλη που φαίνεται στο στιγμιότυπο.

Άσκηση 6:

Για τον υπολογισμό του BMI δημιούργησα μια νέα στήλη με το όνομα BMI. Για οικονομία χώρου και χρόνου, προσέθεσα απλά την στήλη Height (m), για να μπορέσω να αντλήσω δεδομένα.



J4 | =A4/A17

| | A | C | D | F | H | J |
|---|---|---|---|---|---|---|
| 3 | Weight (Kg) | | | Norm. Weight(Kg) | Bin. Weight(Kg) | BMI |
| 4 | 50 | Min Weight(Kg) | Max Weight(Kg) | 0,095 | Low | 32,895 |
| 5 | 115 | 41 | 136 | 0,779 | High | 64,972 |
| 6 | 96 | | | 0,579 | Medium | 52,459 |
| 7 | 41 | | | 0 | Low | 26,452 |
| 8 | 79 | New MIN | 0 | 0,4 | Medium | 43,407 |
| 9 | 109 | New MAX | 1 | 0,716 | High | 57,672 |
| 10 | 73 | | | 0,337 | Medium | 41,477 |
| 11 | 104 | | | 0,663 | High | 60,819 |
| 12 | 64 | | | 0,242 | Medium | 36,782 |
| 13 | 136 | | | 1 | High | 76,404 |
| 16 | Height(m) | | | | | |
| 17 | 1,52 | | | | | |
| 18 | 1,77 | | | | | |
| 19 | 1,83 | | | | | |
| 20 | 1,55 | | | | | |
| 21 | 1,82 | | | | | |
| 22 | 1,89 | | | | | |
| 23 | 1,76 | | | | | |
| 24 | 1,71 | | | | | |
| 25 | 1,74 | | | | | |
| 26 | 1,78 | | | | | |

Με μια απλή διαίρεση γέμισα τα κελιά του πίνακα.

Σε ένα νέο φύλλο συγκέντρωσα όλα τα δεδομένα του προβλήματος. Καταλήγουμε στον παρακάτω πίνακα.

| Name | Age | Gender | Blood Group | Weight(Kg) | Height(m) | Systolic blood pressure | Diastolic blood pressure | Temperature(F) | Diabetes | Norm. Weight(Kg) | Bin. Weight(Kg) | BMI |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| P.Lee | 35 | Female | A Rh+ | 50 | 1,52 | 68 | 112 | 98,7 | 0 | 0,095 | High | 32,895 |
| R.Jones | 52 | Male | A Rh- | 115 | 1,77 | 110 | 154 | 98,5 | 1 | 0,779 | High | 64,972 |
| J.Smith | 45 | Male | A Rh+ | 96 | 1,83 | 88 | 136 | 98,8 | 0 | 0,579 | Medium | 52,459 |
| A.Patel | 70 | Female | A Rh- | 41 | 1,55 | 76 | 125 | 98,6 | 0 | 0,000 | Low | 26,452 |
| M.Owen | 24 | Male | A Rh- | 79 | 1,82 | 65 | 105 | 98,7 | 0 | 0,400 | Medium | 43,407 |
| S.Green | 43 | Male | A Rh- | 109 | 1,89 | 114 | 159 | 98,9 | 1 | 0,716 | High | 57,672 |
| N.Cook | 68 | Male | A Rh+ | 73 | 1,76 | 108 | 136 | 99 | 0 | 0,337 | Medium | 41,477 |
| W.Hanks | 77 | Female | A Rh- | 104 | 1,71 | 107 | 145 | 98,3 | 1 | 0,663 | High | 60,819 |
| P.Rice | 45 | Female | A Rh+ | 64 | 1,74 | 101 | 132 | 98,6 | 0 | 0,242 | Medium | 36,782 |
| F.Marsh | 28 | Male | A Rh+ | 136 | 1,78 | 121 | 165 | 98,7 | 1 | 1,000 | High | 76,404 |

Με μια μικρή κλίμακα φαίνονται τα τελικά δεδομένα του προβλήματος.

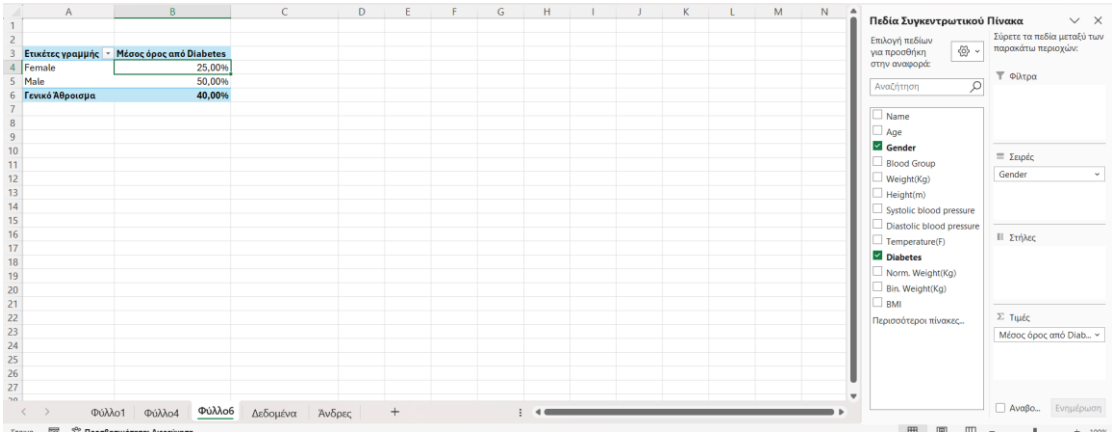
Άσκηση 7:

Για αυτήν την άσκηση έκανα χρήση του Συγκεντρωτικού Πίνακα στο Excel. Επέλεξα όλα τα δεδομένα του προβλήματος και ζήτησα την δημιουργία σε ένα νέο Φύλλο του πίνακα. Παρακάτω φαίνεται και ένα στιγμιότυπο.

| Ετικέτες γραμμής | Μέσος όρος από Diabetes |
|---|---|
| Female | 25,00% |
| Male | 50,00% |
| **Γενικό Άθροισμα** | **40,00%** |

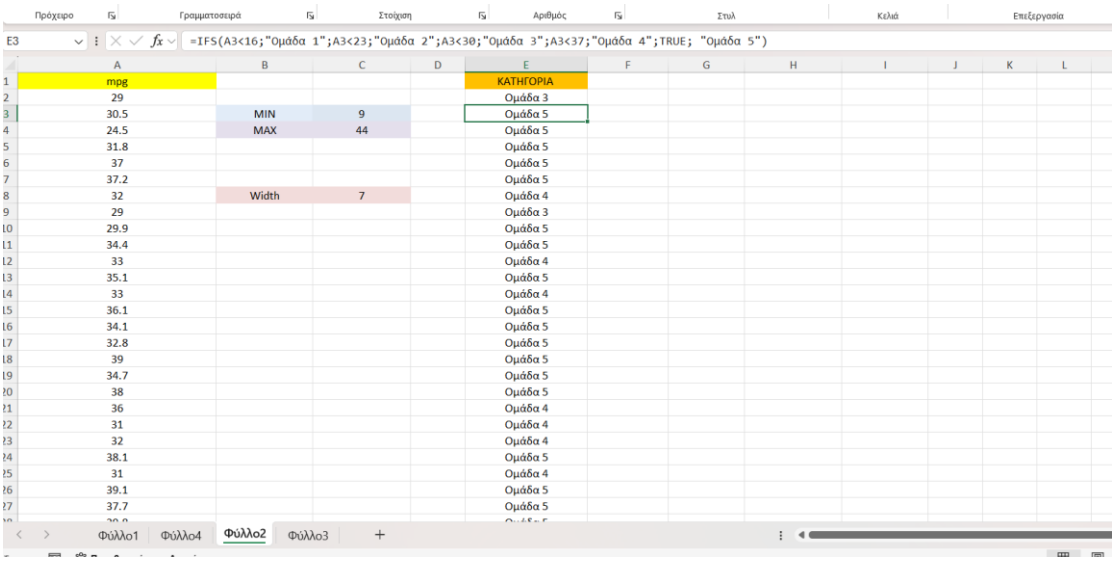
Από εδώ παρατηρούμε ότι γενικά το 40% του δείγματος έχει διαβήτη, το 25% των γυναικών είναι ασθενής, καθώς και πως οι μισοί άνδρες του δείγματος έχουν διαβήτη.

Παρακάτω φαίνονται μερικές ρυθμίσεις που έγιναν στον πίνακα.



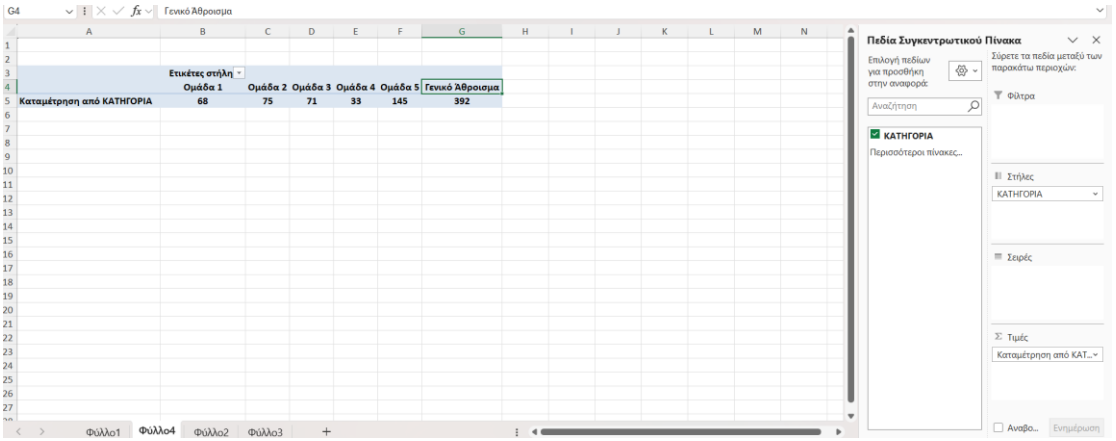

✓ Εφαρμογή /Διαφάνειες/Διακριτοποίηση

Για την απάντηση αυτή της άσκησης, κατέβασα το αρχείο στον υπολογιστή και σε πρώτη φάση με τις συναρτήσεις MIN/MAX βρήκα το ελάχιστο και το μέγιστο της στήλης αυτής. Επίσης, για να μην πειράξω το αρχικό dataset αντέγραψα την στήλη σε ένα καινούργιο φύλλο για να την διαχειριστώ πιο εύκολα.



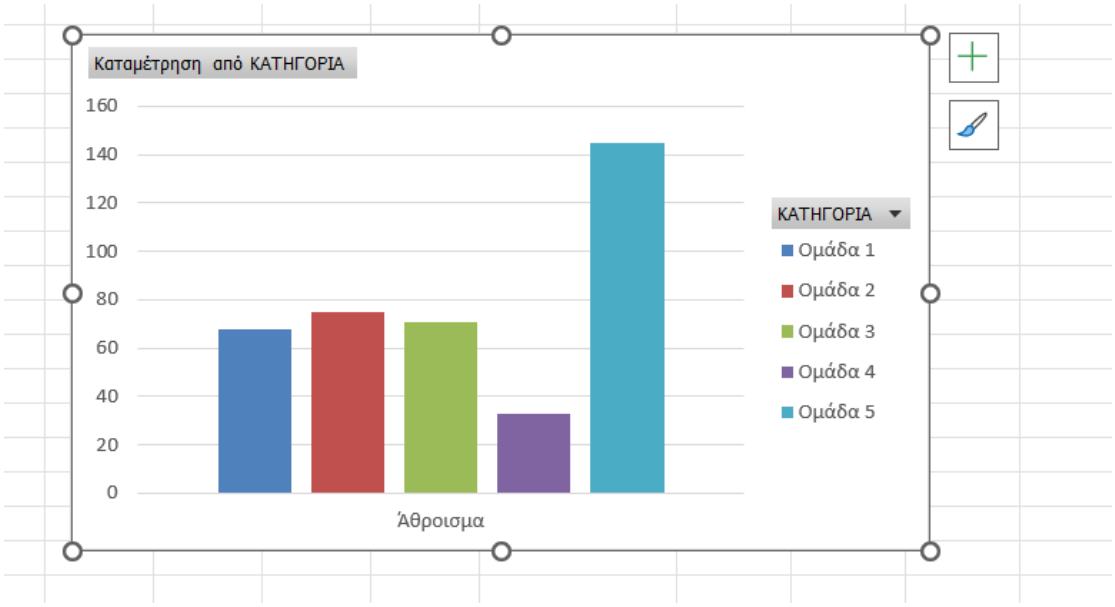

Αφού βρήκα το ελάχιστο και το μέγιστο, βρήκα το πλάτος/εύρος κάθε μιας ομάδας (Width) , έστω να μπορώ να ορίσω τα όρια μέσα στα οποία προσδιορίζεται κάθε κατηγορία. Στην εικόνα φαίνεται και η χρήση της συνάρτησης που έκανα με πολλαπλές δομές IF, ώστε να καταλήξουμε στην εκάστοτε κατηγορία.

Τέλος, για το τελικό συμπέρασμα δημιούργησα έναν συγκεντρωτικό πίνακα που δείχνει το πλήθος των στοιχείων που περιέχει κάθε ομάδα.




Για τις σειρές και τις τιμές χρησιμοποίησα την ίδια στήλη ΚΑΤΗΓΟΡΙΑ που ήταν το αποτέλεσμα της προηγούμενης διαδικασίας, με καταμέτρηση των τιμών. Παρατηρούμε από την στήλη Γενικό Άθροισμα, πως δεν ξέφυγε κάποια τιμή από τις μετρήσεις μας, αφού σαν αποτέλεσμα έχουμε το 392.

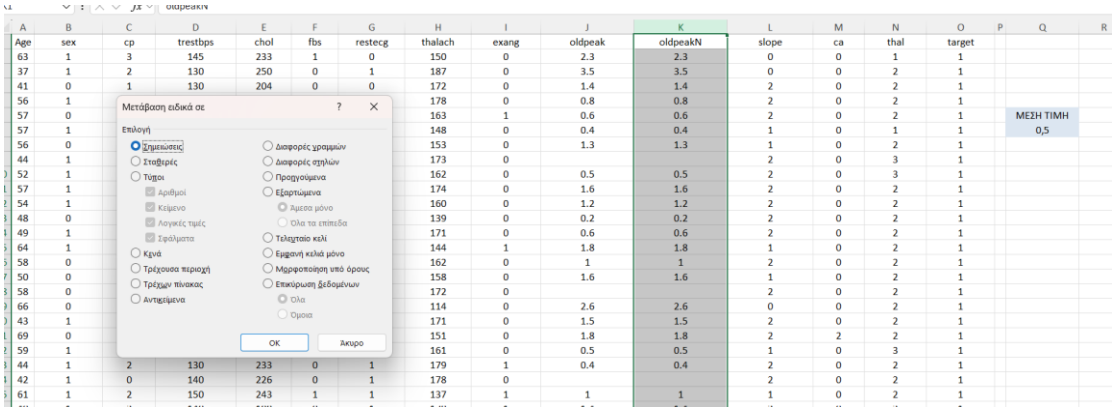
Για οπτικοποιήση των παραπάνω δεδομένων έκανα χρήση του συγκεντρωτικού γραφήματος, το οποίο είναι το παρακάτω.



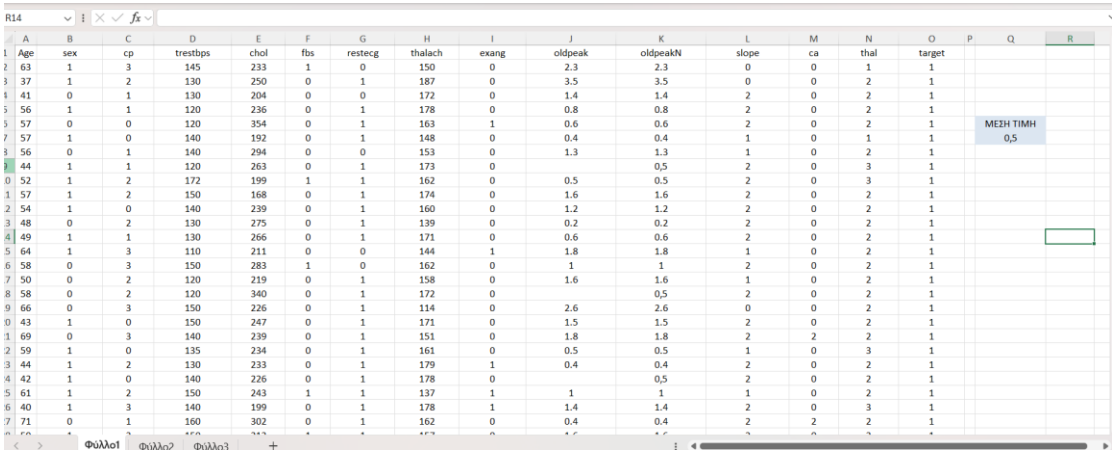

✓ Εφαρμογή/Διαφάνειες/ Καθαρισμός

Για την εύρεση της μέσης τιμής, χρησιμοποίησα την συνάρτηση AVERAGE του Excel. Γενικά, καλό είναι να αποφεύγεται ο μέσος όρος, όμως στο Excel η συνάρτηση αυτή δεν υπολογίζει τα κενά, οπότε θα λάβουμε μια μέτρηση πιο κοντά στην πραγματική.

Αντέγραψα τα στοιχεία της στήλης oldpeak σε μια καινουργία διπλανή στήλη με την ονομασία oldpeakN. Επέλεξα την καινούργια στήλη και πατώντας F5, εμφανίστηκε ένα pop up παράθυρο όπως φαίνεται στην εικόνα. Επίσης, στην εικόνα φαίνεται και η Μέση τιμή στο χρωματισμένο κελί.



Αφού επέλεξα τα κενά, κάθε κενό είχε ένα πράσινο πλαίσιο γύρω του. Πάτησα στο πρώτο κενό την τιμή της μέσης και μετά με Ctrl + Enter, αυτόματα όλα τα κενά κελιά γέμισαν και πήραν την τιμή 0,5.



| Age | sex | cp | trestbps | chol | fbs | restecg | thalach | exang | oldpeak | oldpeakN | slope | ca | thal | target | | |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 63 | 1 | 3 | 145 | 233 | 1 | 0 | 150 | 0 | 2.3 | 2.3 | 0 | 0 | 1 | 1 | | |
| 37 | 1 | 2 | 130 | 250 | 0 | 1 | 187 | 0 | 3.5 | 3.5 | 0 | 0 | 2 | 1 | | |
| 41 | 0 | 1 | 130 | 204 | 0 | 0 | 172 | 0 | 1.4 | 1.4 | 2 | 0 | 2 | 1 | | |
| 56 | 1 | 1 | 120 | 236 | 0 | 1 | 178 | 0 | 0.8 | 0.8 | 2 | 0 | 2 | 1 | | |
| 57 | 0 | 0 | 120 | 354 | 0 | 1 | 163 | 1 | 0.6 | 0.6 | 2 | 0 | 2 | 1 | ΜΕΣΗ ΤΙΜΗ | |
| 57 | 1 | 0 | 140 | 192 | 0 | 1 | 148 | 0 | 0.4 | 0.4 | 1 | 0 | 1 | 1 | 0,5 | |
| 56 | 0 | 1 | 140 | 294 | 0 | 0 | 153 | 0 | 1.3 | 1.3 | 1 | 0 | 2 | 1 | | |
| 44 | 1 | 1 | 120 | 263 | 0 | 1 | 173 | 0 | | 0,5 | 2 | 0 | 3 | 1 | | |
| 52 | 1 | 2 | 172 | 199 | 1 | 1 | 162 | 0 | 0.5 | 0.5 | 2 | 0 | 3 | 1 | | |
| 57 | 1 | 2 | 150 | 168 | 0 | 1 | 174 | 0 | 1.6 | 1.6 | 2 | 0 | 2 | 1 | | |
| 54 | 1 | 0 | 140 | 239 | 0 | 1 | 160 | 0 | 1.2 | 1.2 | 2 | 0 | 2 | 1 | | |
| 48 | 0 | 2 | 130 | 275 | 0 | 1 | 139 | 0 | 0.2 | 0.2 | 2 | 0 | 2 | 1 | | |
| 49 | 1 | 1 | 130 | 266 | 0 | 1 | 171 | 0 | 0.6 | 0.6 | 2 | 0 | 2 | 1 | | |
| 64 | 1 | 3 | 110 | 211 | 0 | 0 | 144 | 1 | 1.8 | 1.8 | 1 | 0 | 2 | 1 | | |
| 58 | 0 | 3 | 150 | 283 | 1 | 0 | 162 | 0 | 1 | 1 | 2 | 0 | 2 | 1 | | |
| 50 | 0 | 2 | 120 | 219 | 0 | 1 | 158 | 0 | 1.6 | 1.6 | 1 | 0 | 2 | 1 | | |
| 58 | 0 | 2 | 120 | 340 | 0 | 1 | 172 | 0 | | 0,5 | 2 | 0 | 2 | 1 | | |
| 66 | 0 | 3 | 150 | 226 | 0 | 1 | 114 | 0 | 2.6 | 2.6 | 0 | 0 | 2 | 1 | | |
| 43 | 1 | 0 | 150 | 247 | 0 | 1 | 171 | 0 | 1.5 | 1.5 | 2 | 0 | 2 | 1 | | |
| 69 | 0 | 3 | 140 | 239 | 0 | 1 | 151 | 0 | 1.8 | 1.8 | 2 | 2 | 2 | 1 | | |
| 59 | 1 | 0 | 135 | 234 | 0 | 1 | 161 | 0 | 0.5 | 0.5 | 1 | 0 | 3 | 1 | | |
| 44 | 1 | 2 | 130 | 233 | 0 | 1 | 179 | 1 | 0.4 | 0.4 | 2 | 0 | 2 | 1 | | |
| 42 | 1 | 0 | 140 | 226 | 0 | 1 | 178 | 0 | | 0,5 | 2 | 0 | 2 | 1 | | |
| 61 | 1 | 2 | 150 | 243 | 1 | 1 | 137 | 1 | 1 | 1 | 1 | 0 | 2 | 1 | | |
| 40 | 1 | 3 | 140 | 199 | 0 | 1 | 178 | 1 | 1.4 | 1.4 | 2 | 0 | 3 | 1 | | |
| 71 | 0 | 1 | 160 | 302 | 0 | 1 | 162 | 0 | 0.4 | 0.4 | 2 | 2 | 2 | 1 | | |

- ✓ Εφαρμογή/Διαφάνειες/ Κανονικοποίηση

Έχουμε ξανά το αρχείο heart.xlsx και την μεταβλητή chol. Για να διευκολυνθεί πάλι η ανάλυση και να μειώσουμε τον ρίσκο παραποίησης των αρχικών δεδομένων αντιγράφω την στήλη σε νέο φύλλο.

Δημιουργώ την νέα στήλη Chol.Norm, την οποία γεμίζω με την συνάρτηση που φαίνεται στην εικόνα και την χρήση των $ για να κλειδώσω της σταθερές τιμές και να μην αλλάζουν κάθε φορά.

G3: `= ((A3-$E$2)/($E$3 -$E$2))/($E$6 -$E$5)+$E$5`

| | A | D | E | G |
|---|---|---|---|---|
| 1 | chol | | | Chol.Norm |
| 2 | 233 | MIN | 126 | 0,244 |
| 3 | 250 | MAX | 564 | 0,283 |
| 4 | 204 | | | 0,178 |
| 5 | 236 | New Min | 0 | 0,251 |
| 6 | 354 | New Max | 1 | 0,521 |
| 7 | 192 | | | 0,151 |
| 8 | 294 | | | 0,384 |
| 9 | 263 | | | 0,313 |
| 10 | 199 | | | 0,167 |
| 11 | 168 | | | 0,096 |
| 12 | 239 | | | 0,258 |
| 13 | 275 | | | 0,340 |
| 14 | 266 | | | 0,320 |
| 15 | 211 | | | 0,194 |
| 16 | 283 | | | 0,358 |
| 17 | 219 | | | 0,212 |
| 18 | 340 | | | 0,489 |
| 19 | 226 | | | 0,228 |
| 20 | 247 | | | 0,276 |
| 21 | 239 | | | 0,258 |
| 22 | 234 | | | 0,247 |
| 23 | 233 | | | 0,244 |
| 24 | 226 | | | 0,228 |
| 25 | 243 | | | 0,267 |
| 26 | 199 | | | 0,167 |
| 27 | 302 | | | 0,402 |

Είναι λογικό πως σε αντιστοιχία με την μικρότερη τιμή η κανονικοποιημένη μεταβλητή chol θα έχει την τιμή 0, ενώ στο μεγαλύτερο την τιμή 1.