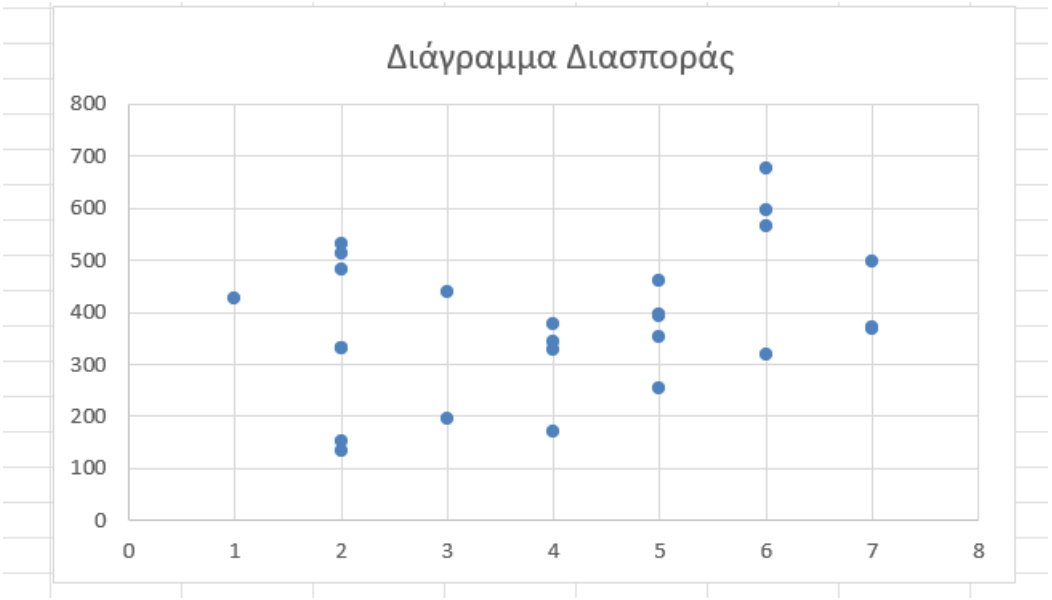
Εφαρμογή/σελίδα 88:

1)Σε πρώτη φάση κατασκευάστηκε το διάγραμμα διασποράς των δεδομένων του δείγματος.



Εικόνα 1Διάγραμμα Διασποράς

Στο διάγραμμα διασποράς παρουσιάζεται η σχέση μεταξύ του αριθμού των καταχωρήσεων (άξονας Χ) και του αριθμού των πελατών (άξονας Υ). Τα δεδομένα δεν φαίνεται να συγκεντρώνονται γύρω από μια ευθεία γραμμή. Αντιθέτως φαίνονται διασκορπισμένα στον χώρο, αλλά με μια ασθενή θετική τάση, καθώς σε κάποιες περιπτώσεις μεγαλύτερος αριθμός καταχωρήσεων συνεπάγεται με μεγαλύτερο αριθμό πελατών.

Στην συνέχεια, προχωράμε στην διαδικασία της παλινδρόμησης. Για αυτό χρησιμοποιήθηκε από την επέκταση «Ανάλυση Δεδομένων» η Παλινδρόμηση (Regression).

	A	B	C	D	E	F	G	H	I
1	ΈΞΟΔΟΣ ΣΥΜΠΕΡΑΣΜΑΤΟΣ								
2									
3	*Στατιστικά παλινδρόμησης*								
4	Πολλαπλό R	0,292							
5	R Τετράγωνο	0,085							
6	Προσαρμοσμένο R Τετράγωνο	0,047							
7	Τυπικό σφάλμα	132,960							
8	Μέγεθος δείγματος	26							
9									
10	ΑΝΑΛΥΣΗ ΔΙΑΚΥΜΑΝΣΗΣ								
11		*βαθμοί ελευθερίας*	*SS*	*MS*	*F*	*Σημαντικότητα F*			
12	Παλινδρόμηση	1	39520,86	39520,86	2,24	0,15			
13	Υπόλοιπο	24	424281,17	17678,38					
14	Σύνολο	25	463802,04						
15									
16		*Συντελεστές*	*Τυπικό σφάλμα*	*t*	*τιμή-P*	*Κατώτερο 95%*	*Υψηλότερο 95%*	*Κατώτερο 95,0%*	*Υψηλότερο 95,0%*
17	Τεταγμένη επί την αρχή	296,92	64,31	4,62	0,00	164,20	429,64	164,20	429,64
18	Καταχωρήσεις	21,36	14,28	1,50	0,15	-8,12	50,84	-8,12	50,84
19									
20									
21									
22	Ευθεία Παλινδρόμησης	Y = 296,92 + 21,36X							
23									

Εικόνα 2 Παλινδρόμηση

Από τα παραπάνω προκύπτει πως η ευθεία παλινδρόμησης είναι η ακόλουθη:

$$Y = 296,92 + 21,36X$$

2)Η ανεξάρτητη μεταβλητή X, είναι οι καταχωρήσεις των διαφημίσεων και η εξαρτημένη Y είναι ο αριθμός των πελατών. Από αυτήν την ευθεία μπορούμε να καταλάβουμε από το μοντέλο ότι αν δεν γίνει καμία διαφημιστική καταχώρηση, προβλέπει περίπου 297 πελάτες, ενώ κάθε διαφημιστική καταχώρηση οδηγεί σε αύξηση του αριθμού των πελάτων περίπου κατά 21 μέσο όρο.

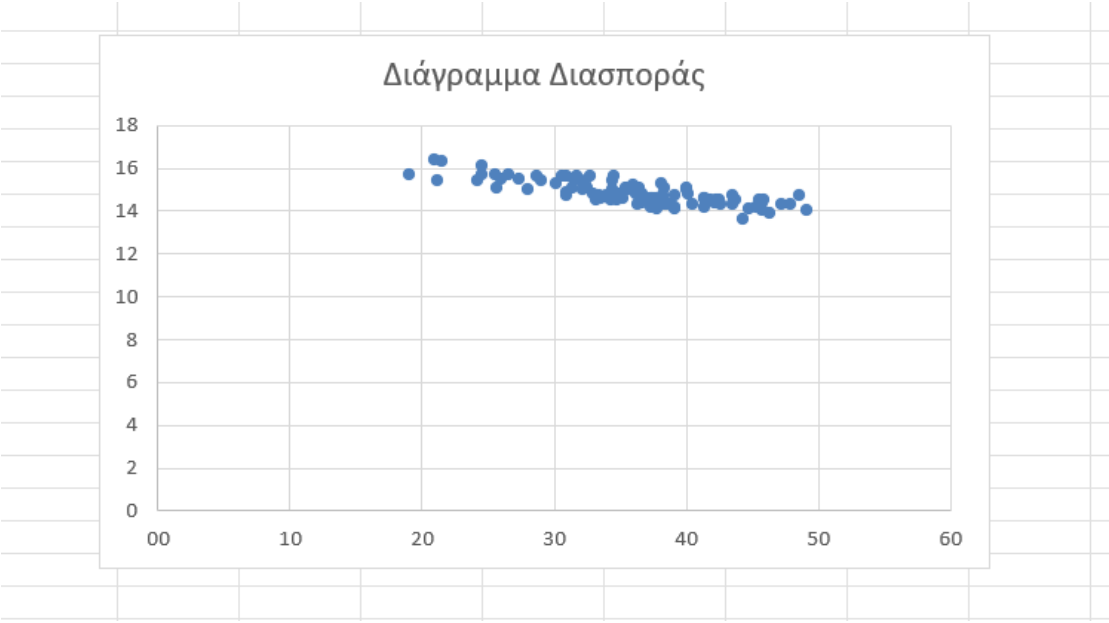
3) Για να δούμε αν μπορεί το τμήμα των πωλήσεων μπορεί να συμπεράνει ότι περισσότερες διαφημίσεις αντιστοιχούν σε περισσότερους πελάτες, πρέπει να εξετάσουμε την σχέση μεταξύ των δύο μεταβλητών. Βάσει της εικόνας 2, κοιτώντας την τιμή της p-value από την σειρά Καταχωρήσεις. Αφού η τιμή της p-value > 0.05, δεν υπάρχουν σημαντικές στατιστικές ενδείξεις ότι οι δύο μεταβλητές έχουν κάποια συσχέτιση, άρα δεν μπορούμε στατιστικώς να συμπεράνουμε ότι κάθε διαφήμιση θα επιφέρει περισσότερους πελάτες.

4) Ο συντελεστής προσδιορισμού βρίσκεται στο κελί R Τετράγωνο του Excel στης εικόνας 2. Επομένως, έχουμε R^2 = 0.085 ή 8,5%. Αυτό σημαίνει ότι το 8,5% της μεταβλητότητας του αριθμού των πελατών οφείλεται στις διαφημίσεις, ενώ το υπόλοιπο 91,5% οφείλεται σε διαφορετικούς παράγοντες.

5) Αν και το 5 ανήκει στο εύρος των παρατηρήσεων, δεν μπορούμε να χρησιμοποιήσουμε την συνάρτηση παλινδρόμησης για να προβλέψουμε τους πελάτες. Αυτό γιατί έχουμε τυπικό σφάλμα εκτίμησης R^2 = 0,085, που είναι αρκετά χαμηλό, p – value = 0.15, που με βάση την δοκιμασία ANOVA σημαίνει ότι στατιστικά το αποτέλεσμα δεν είναι ισχυρό και τέλος βάσει του συντελεστή προσδιορισμού, η συσχέτιση παρουσιάζεται ως ασθενής. Άρα, το μοντέλο δεν ταιριάζει στα δεδομένα. Μόνο με επιφύλαξη, μπορούμε με αντικατάσταση στην ευθεία, η αύξηση του αριθμού των πελατών θα είναι περίπου 404.

Εφαρμογή/σελίδα 89:

1)Για αρχή κατασκευάζουμε το διάγραμμα διασποράς προκειμένου, να έχουμε μια πρώτη εικόνα της σχέσης των μεταβλητών.



Εικόνα 3 Διάγραμμα Διασποράς

Από το διάγραμμα, φαίνεται πως οι δύο μεταβλητές έχουν μια φθίνουσα σχέση. Στον άξονα Χ, βρίσκεται η ανεξάρτητη μεταβλητή, η οποία σε αυτήν την περίπτωση είναι ο αριθμός των κοντέρ και στον άξονα Υ βρίσκεται η εξαρτημένη που στην συγκεκριμένη περίπτωση είναι η τιμή του αυτοκινήτου.

Από την επέκταση Ανάλυση δεδομένων, επιλέγουμε την παλινδρόμηση και λαμβάνουμε τα παρακάτω αποτελέσματα.

	A	B	C	D	E	F	G	H	I
1	ΈΞΟΔΟΣ ΣΥΜΠΕΡΑΣΜΑΤΟΣ								
2									
3	*Στατιστικά παλινδρόμησης*								
4	Πολλαπλό R	0,81							
5	R Τετράγωνο	0,65							
6	Προσαρμοσμένο R Τετράγωνο	0,64							
7	Τυπικό σφάλμα	0,33							
8	Μέγεθος δείγματος	100							
9									
10	ΑΝΑΛΥΣΗ ΔΙΑΚΥΜΑΝΣΗΣ								
11		*βαθμοί ελευθερίας*	*SS*	*MS*	*F*	*Σημαντικότητα F*			
12	Παλινδρόμηση	1	19,26	19,26	180,64	0,00			
13	Υπόλοιπο	98	10,45	0,11					
14	Σύνολο	99	29,70						
15									
16		*Συντελεστές*	*Τυπικό σφάλμα*	*t*	*τιμή-P*	*Κατώτερο 95%*	*Υψηλότερο 95%*	*Κατώτερο 95,0%*	*Υψηλότερο 95,0%*
17	Τεταγμένη επί την αρχή	17,25	0,18	94,73	0,00	16,89	17,61	16,89	17,61
18	Μεταβλητή Χ 1	-0,07	0,00	-13,44	0,00	-0,08	-0,06	-0,08	-0,06
19									
20									
21									
22	Ευθεία Παλινδρόμησης	Y = 17,25 - 0,07X							
23									
24									
25									

Εικόνα 4 Παλινδρόμηση για αυτοκίνητα

Από το υπολογιστικό αυτό φύλλο καταλαβαίνουμε ότι η ευθεία παλινδρόμησης είναι η εξής:

$$Y = 17,25 - 0,07X$$

2)Εδώ παρατηρούμε ότι το συγκεκριμένο μοντέλο που είναι τριών ετών, αν πουληθεί με μηδενικά μίλια στο κοντέρ θα έχει τιμή 17,25 χιλιάδες δολάρια. Ενώ για κάθε χίλια μίλια που γράφει το κοντέρ παραπάνω, έχουμε πτώση της τιμής του αυτοκινήτου κατά 0,07 χιλιάδες δολάρια.

3) Για να δούμε αν ο έμπορος μπορεί να συμπεράνει ότι αύξηση των μιλίων σημαίνει μείωση της τιμής, πρέπει να εξετάσουμε την p-value. Έχουμε p- value μεταβλητής Χ1 ίση με 0,00 < 0,05, υπάρχουν σημαντικές στατιστικές ενδείξεις ότι η αύξηση της μιας τιμής, οδηγεί σε πτώση της άλλης. Επομένως, ναι ο έμπορος μπορεί να συμπεράνει πτώση της τιμής, όταν τα μίλια αυξάνονται.

4) Ο συντελεστής προσδιορισμού είναι το R τετράγωνο στο παραπάνω υπολογιστικό φύλλο. Στην συγκεκριμένη περίπτωση ισούται με 0,65 ή 65%. Αυτό σημαίνει ότι το 65% της μεταβλητότητας της τιμής οφείλεται στις αλλαγές των μετρήσεων του κοντέρ και το υπόλοιπο 35% οφείλεται σε άλλους παράγοντες.

5)Ναι, μπορούμε να χρησιμοποιήσουμε την συνάρτηση παλινδρόμησης. Αρχικά, γιατί το 40,000 ανήκει στο εύρος των παρατηρήσεων. Δεύτερόν, έχουμε p-value = 0.00 < 0.05, όπου από την διαδικασία ANOVA, σημαίνει ότι το αποτέλεσμα έχει στατιστική ισχύ και τέλος, από τον συντελεστή προσδιορισμού διακρίνουμε μια ισχυρή στατιστική συσχέτιση. Επομένως, με αντικατάσταση καταλήγουμε στο ότι:

$$Y = 17,25 - 0,007X$$

⇨ Y = 17,25 -0,07*40

⇨ Y = 14,45

Στον τύπο αντικαταστήσαμε το X με το 40, καθώς η εξίσωση έχει κατασκευαστεί, απλοποιημένη χωρίς πολλά μηδενικά.