Πασχαλίνα Κωνσταντινίδου, bad26014

Ανάλυση του αρχείου adults_data

Ποιοτικές Μεταβλητές

Διέτρεξα το αρχείο για να βρω τις τιμές NA, με τα φίλτρα που διαθέτει το Excel. Επειδή υπήρχαν σε αρκετές γραμμές τέτοιες εγγραφές ακόμα και σε δύο στήλες, αποφάσισα να τις διαγράψω, αφού δεν μπορούσα να τις αντικαταστήσω κάπως, όντας κατηγορικές μεταβλητές. Αυτό μείωσε το μέγεθος του δείγματος από 32561 εγγραφές σε 30154.

Στο φύλλο «Ποιοτικές Μεταβλητές» φαίνονται οι συγκεντρωτικοί πίνακες με τις συχνότητες εμφάνισης κάθε τιμής. Αφού έγινε καταμέτρηση κάθε τιμής, στην συνέχει παρουσιάστηκε ως ποσοστό (συχνότητα) επί του συνόλου των εγγραφών.

Ενδεικτικά, αναφέρονται μερικά στατιστικά.

Ετικέτες γραμμής	Καταμέτρηση από workclass
Federal-gov	3,13%
Local-gov	6,85%
Private	73,88%
Self-emp-inc	3,56%
Self-emp-not-inc	8,29%
State-gov	4,24%
Without-pay	0,05%
Γενικό Άθροισμα	**100,00%**

Εικόνα 1 Συχνότητες workclass

Εδώ βλέπουμε πως σχεδόν το 74% του δείγματος δουλεύει στον ιδιωτικό τομέα.

Ετικέτες γραμμής	Καταμέτρηση από sex
Female	32,42%
Male	67,58%
Γενικό Άθροισμα	**100,00%**

Εικόνα 2 Συχνότητες Φύλου

Το 32,42% του δείγματος είναι γυναίκες, ενώ σχεδόν το 68% είναι άντρες.

Ετικέτες γραμμής	Καταμέτρηση από education
10th	2,72%
11th	3,48%
12th	1,25%
1st-4th	0,50%
5th-6th	0,96%
7th-8th	1,84%
9th	1,50%
Assoc-acdm	3,34%
Assoc-voc	4,33%
Bachelors	16,72%
Doctorate	1,24%
HS-grad	32,63%
Masters	5,40%
Preschool	0,15%
Prof-school	1,80%
Some-college	22,14%

Εικόνα 3 Συχνότητες Εκπαίδευσης

Το 32,63% έχουν επίπεδο εκπαίδευσης HS- grad.

Τέλος, φαίνεται πως το 86% του δείγματος ανήκουν στην φυλή «White», ενώ το 91,21% του δείγματος είναι από τις Ηνωμένες Πολιτείες Αμερικής.

Ετικέτες γραμμής	Καταμέτρηση από race
Amer-Indian-Eskimc	0,95%
Asian-Pac-Islander	2,94%
Black	9,34%
Other	0,77%
White	86,00%
Γενικό Άθροισμα	**100,00%**

Εικόνα 4 Συχνότητες race

Ετικέτες γραμμής	Καταμέτρηση από native country
Cambodia	0,06%
Canada	0,35%
China	0,20%
Columbia	0,19%
Cuba	0,31%
Dominican-Republic	0,22%
Ecuador	0,09%
El-Salvador	0,33%
England	0,29%
France	0,09%
Germany	0,42%
Greece	0,10%
Guatemala	0,21%
Haiti	0,14%
Holand-Netherlands	0,00%
Honduras	0,04%
Hong	0,06%
Hungary	0,04%
India	0,33%
Iran	0,14%
Ireland	0,08%
Italy	0,23%
Jamaica	0,27%
Japan	0,20%
Laos	0,06%
Mexico	2,02%
Nicaragua	0,11%
Outlying-US(Guam-USVI-etc)	0,05%
Peru	0,10%
Philippines	0,62%
Poland	0,19%
Portugal	0,11%
Puerto-Rico	0,36%
Scotland	0,04%
South	0,24%
Taiwan	0,14%
Thailand	0,06%
Trinadad&Tobago	0,06%
United-States	91,21%
Vietnam	0,21%
Yugoslavia	0,05%
Γενικό Άθροισμα	**100,00%**

Εικόνα 5 Συχνότητες native country

Ποσοτικές Μεταβλητές

Τα περιγραφικά στατιστικά στοιχεία των ποσοτικών μεταβλητών φαίνονται στο φύλλο «Ποσοτικές Μεταβλητές». Για κάθε μια χρησιμοποιήθηκαν τα κατάλληλα μέτρα.

Για την μεταβλητή age, που περιγράφει την ηλικία των ατόμων του δείγματος. Ο μέσος όρος είναι 38,44 έτη, με ελάχιστη τιμή το 17 και μέγιστη το 90. Η τυπική απόκλιση είναι 13,14, αυτό σημαίνει ότι έχουμε ένα μεγάλο εύρος τιμών, δηλαδή καλύπτουμε το μεγαλύτερο ποσοστό του πληθυσμού, από τους πιο μικρούς έως και τους πιο μεγάλους.

age	
Μέσος	38,44
Μέση απόκλιση τετραγώνου	13,14
Ελάχιστο	17
Μέγιστο	90
Πλήθος	30154

Εικόνα 6 Στατιστικά για age

Για τις μεταβλητές capital loss και capital gain, τα αποτελέσματα είναι λίγο περίεργα, αφού οι περισσότεροι δεν είχαν ούτε κέρδος ούτε ζημία. Και στα δύο οι διάμεσοι είναι ίσοι με το 0, ενώ η μέγιστη ζημία είναι 4356 χρηματικές μονάδες και τα μέγιστα κέρδη είναι 9999.

capital gain	
Μέσος	1092,30
Διάμεσος	0
Ελάχιστο	0
Μέγιστο	99999
Πλήθος	30154

Εικόνα 7 Στατιστικά capital gain

capital loss	
Μέσος	88,40
Διάμεσος	0
Ελάχιστο	0
Μέγιστο	4356
Πλήθος	30154

Εικόνα 8 Στατιστικά capital loss

Η μεταβλητή hours per week είναι οι ώρες εργασίας κάθε ανθρώπου την βδομάδα. Ο μέσος όρος είναι 40,93, η επικρατούσα τιμή 40, αυτά τα δύο έχουν ως συμπέρασμα πως η πλειοψηφία των ατόμων του δείγματος δουλεύει 40 ώρες την βδομάδα. Οι μέγιστες ώρες εργασίες είναι 99, κάτι που υποδηλώνει ότι ο συγκεκριμένος άνθρωπος δουλεύει υπερωρίες. Έχουμε μια τυπική απόκλιση 11,98, κάτι που σημαίνει ότι οι περισσότερες τιμές είναι κοντά στο 40. Το 99 ίσως να θεωρείται ακραία τιμή, επειδή η διασπορά στο δείγμα μας δεν είναι τόσο μεγάλη για να θεωρείται μέσα στις αντιπροσωπευτικές τιμές.

hours per week	
Μέσος	40,93
Διάμεσος	40
Μέση απόκλιση τετραγώνου	11,98
Μέγιστο	99
Πλήθος	30154

Εικόνα 9 Στατιστικά hours per week

Η μεταβλητή final weight, εκφράζει το βάρος του δείγματος, ουσιαστικά της δειγματοληψίας, δηλαδή το κατά πόσο κάθε εγγραφή/ γραμμή είναι αντιπροσωπευτική

για τον πληθυσμό. Παρουσιάζονται διάφορα μέτρα στην εικόνα, όπως το πιο σημαντικό θεωρείται η διάμεσος, η οποία δείχνει το πόσο ομοιόμορφο ή όχι είναι το δείγμα, στην συγκεκριμένη περίπτωση.

final weight	
Διάμεσος	178430
Ελάχιστο	13769
Μέγιστο	1484705
Πλήθος	30154

Εικόνα 10 Στατιστικά final weight

Τέλος, για την μεταβλητή education number έχουμε έναν μέσο όρο 10,12, με τυπική απόκλιση 2,55 και διάμεσο 10. Αυτό σημαίνει πως οι περισσότεροι έχουν επίπεδο εκπαίδευσης 10, εκφρασμένο ως αριθμό, δηλαδή έχουν σπουδάσει σε κάποιο κολλέγιο. Η τυπική απόκλιση δείχνει μια σχετική ομοιομορφία στην εκπαίδευση του δείγματος, αφού οι περισσότερες τιμές βρίσκονται κοντά στο 10.

education number	
Μέσος	10,12
Διάμεσος	10
Μέση απόκλιση τετραγώνου	2,55
Ελάχιστο	1
Μέγιστο	16
Πλήθος	30154

Εικόνα 11 Στατιστικά educational number

Σημείωση: σε όλες τις ποσοτικές μεταβλητές υπάρχει και το πλήθος, το οποίο το χρησιμοποίησα μόνο και μόνο για να επαληθεύσω αν όλα τα δεδομένα λήφθηκαν υπόψιν και δεν ξέφυγε κάποιο από την ανάλυση, δεν έχει κάποια αξία στην περιγραφή της μεταβλητής.