Άσκηση 1/ Διάλεξη 10:

Για την εκπόνηση αυτής της άσκησης, έγινε χρήση του Excel. Για να απαντηθούν τα ερωτήματα, δημιουργήθηκαν κάποια επιπλέον φύλλα. Στο φύλλο Ανάλυση για Χρόνο, έχουν συγκεντρωθεί τα απαραίτητα δεδομένα για να υπολογιστεί ο χρόνος για κάθε φύλο.

Άντρες	Γυναίκες
10	15
120	40
30	30
25	120
50	40
35	90
30	20
60	45
30	80
25	45
100	40
0	30
25	20
45	90
60	45
30	60
45	25
25	50
30	50
20	45

Μέσος όρος Άντρες	39,75
Μέσος Όρος Γυναίκες	49
Τ.Απόκλιση_Άντρες	28,35
Τ.Απόκλιση_Γυναίκες	27,08
Πλήθος Αντρών	20
Πλήθος Γυναικών	20

Φύλο	Πλήθος	Μέσος όρος	Τυπική Απόκλιση
Άντρες	20	39,75	28,35
Γυναίκες	20	49	27,08

Εικόνα 1 Φύλλο "Ανάλυση για Χρόνο"

Παραπάνω φαίνεται ένα απόσπασμα από το συγκεκριμένο φύλλο. Έχουν υπολογιστεί η μέσοι όροι, οι τυπικές αποκλίσεις και το πλήθος των ατόμων, από κάθε φύλο. Δημιουργήθηκε επίσης, ένας πίνακας που να συγκεντρώνει όλη την πληροφορία. Στην συνέχεια, εφαρμόστηκε ένα t-Test, μέσω του εργαλείου της Ανάλυσης Δεδομένων.

Καθώς οι τυπικές αποκλίσεις και για τα δύο φύλα, είναι αρκετά κοντά μεταξύ τους, επιλέχθηκε το t-Test για 2 μεταβλητές με ίσες διακυμάνσεις.

Παρακάτω φαίνονται τα αποτελέσματα.

Έλεγχος t δύο δειγμάτων με υποθέμενες ίσες διακυμάνσεις		
	Άντρες	*Γυναίκες*
Μέσος	39,75	49
Διακύμανση	803,8815789	733,1578947
Μέγεθος δείγματος	20	20
Διάμεση διακύμανση	768,5197368	
Υποθέμενη διαφορά μέσων	0	
βαθμοί ελευθερίας	38	
t	-1,055150041	
P(T<=t) μονόπλευρη	0,149009692	
t κρίσιμο, μονόπλευρο	1,68595446	
P(T<=t) δίπλευρη	0,298019384	
t κρίσιμο, δίπλευρο	2,024394164	

Εικόνα 2 T-Test για τον Χρόνο

Ορίζουμε τις υποθέσεις:

H_0 : Ο μέσος όρος του χρόνου ανάγνωσης είναι ίδιος και για άντρες και για γυναίκες

H_1: Ο μέσος όρος του χρόνου ανάγνωσης είναι διαφορετικός για άντρες και γυναίκες

Κοιτώντας τον πίνακα, ΔΕΝ απορρίπτεται η μηδενική υπόθεση, αφού:

$$P(T<=t)\ \text{δίπλευρη} = 0{,}298 > p = 0{,}05$$

Κοιτάμε την τιμή της δίπλευρης πιθανότητας, καθώς στην μηδενική υπόθεση δεν έχουμε μια συγκεκριμένη κατεύθυνση, πχ > ή <, αλλά έχουμε =. Οπότε χρειάζεται να κοιτάξουμε και τις δύο κατευθύνσεις.

Αν και υπάρχουν διαφορές στον μέσο όρο του χρόνου ανάγνωσης των ανδρών και των γυναικών, στατιστικά δεν έχουν τόσο μεγάλη επίδραση και σημασία για a = 0.05.

Με παρόμοια λογική, πραγματοποιήθηκε t-test και για τον μέσο όρο του εισοδήματος.

Αρχικά, δημιουργήθηκε ένα νέο φύλλο «Ανάλυση για Εισόδημα», με δομή παρόμοια με αυτήν του χρόνου.

Χαμηλό Εισόδημα	Υψηλό Εισόδημα
15	40
10	120
30	25
35	50
30	120
30	60
40	90
30	25
20	45
45	100
80	45
40	90
0	60
25	30
30	60
20	25
45	50
45	25
50	20
30	
45	

Μέσος Όρος Χαμηλού Εισοδήματος	33,10
Μέσος Όρος Υψηλού Εισοδήματος	56,84
Τ.Απόκλιση Χαμηλού	16,69
Τ.Απόκλιση Υψηλού	32,37
Πλήθος Χαμηλού	21
Πλήθος Υψηλού	19

Εισόδημα	Πλήθος	Μέσος όρος	Τ.Απόκλιση
Χαμηλό	21	33,1	16,69
Υψηλό	19	56,84	32,37

Εικόνα 3 Φύλλο "Ανάλυση για Εισόδημα"

Στην περίπτωση αυτή, επειδή οι τυπικές αποκλίσεις διαφέρουν κατά πολύ μεταξύ τους, επιλέχθηκε το t-Test για δύο μεταβλητές με άνισες διακυμάνσεις.

Παρακάτω φαίνονται, τα αποτελέσματα του t-test.

	A	B	C
1	Έλεγχος t δύο δειγμάτων με υποτιθέμενες άνισες διακυμάνσεις		
2			
3		*Μεταβλητή 1*	*Μεταβλητή 2*
4	Μέσος	33,0952381	56,84210526
5	Διακύμανση	278,6904762	1047,807018
6	Μέγεθος δείγματος	21	19
7	Υποτιθέμενη διαφορά μέσων	0	
8	βαθμοί ελευθερίας	26	
9	t	-2,870905341	
10	P(T<=t) μονόπλευρη	0,004016364	
11	t κρίσιμο, μονόπλευρο	1,70561792	
12	P(T<=t) δίπλευρη	0,008032728	
13	t κρίσιμο, δίπλευρο	2,055529439	
14			

Εικόνα 4 T-Test για Εισόδημα

Ορίζονται οι υποθέσεις:

H_0: Ο μέσος χρόνος ανάγνωσης είναι ίδιος για κάθε κατηγορία εισοδήματος

H_1: Ο μέσος χρόνος ανάγνωσης διαφέρει για κάθε κατηγορία εισοδήματος

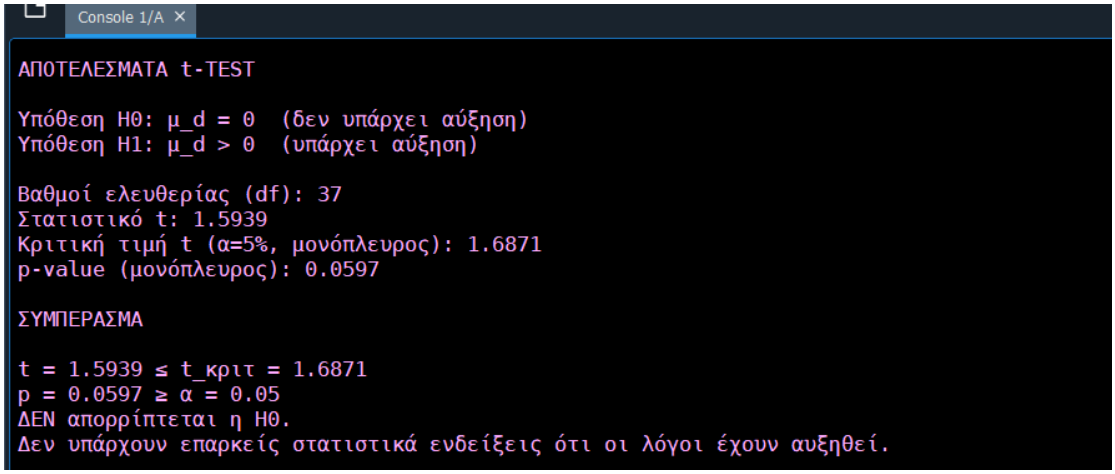
Απορρίπτεται η H_0, αφού:

$$P(T<= t) \text{ δίπλευρη} = 0,008 < p= 0.05$$

Οι μεγάλες διαφορές στον μέσο όρο του χρόνου, αντικατοπτρίζεται στατιστικά για το επίπεδο α = 0,05. Άρα, υπάρχει διαφορά στον μέσο χρόνο ανάγνωσης σε σχέση με το εισόδημα.

Άσκηση 2/Διάλεξη 10:

Για την συγκεκριμένη άσκηση χρησιμοποιήθηκε η Python σε περιβάλλον Spyder, για εξοικονόμηση χρόνου. Ο κώδικας υπάρχει αναλυτικά στο Παράρτημα. Σε αυτό το σημείο, παρουσιάζονται οι υποθέσεις, η μεθοδολογία, τα αποτελέσματα και η ανάλυσή τους.



Εικόνα 5 Άσκηση2

Εδώ ο έλεγχος είναι μονόπλευρος, επειδή η εκφώνηση, ρωτάει αν έχουν αυξηθεί οι λόγοι των αποπληρωμών του χρέους προς το οικογενειακό εισόδημα. Όπως φαίνεται και στο απόσπασμα των αποτελεσμάτων, η H_0 είναι αν η αύξηση των λόγων είναι 0, δηλαδή δεν υπάρχει κάποια μεταβολή και η ενναλακτική είναι αν οι λόγοι αυξήθηκαν.

Παρατηρούμε ότι η πιθανότητα του μονόπλευρου ελέγχου, είναι ελαφρώς μεγαλύτερη από το α = 0,05, το t είναι μικρότερο από την διασπορά των τιμών, άρα από αυτά καταλήγουμε στο συμπέρασμα, πως δεν η H_0 δεν απορρίπτεται, αφού για αυτό το επίπεδο δεν υπάρχει κάποιος στατιστικός λόγος.

Άσκηση 3/Διάλεξη 10:

Ομοίως, με την προηγούμενη άσκηση χρησιμοποιήθηκε Python σε περιβάλλον Spyder. Ο κώδικας υπάρχει στο Παράρτημα.

Για την συγκεκριμένη άσκηση χρησιμοποιούμε τον Έλεγχο Ανεξαρτησίας X^2, αφού έχουμε να κάνουμε με κατηγορίες, το υπόβαθρο και την προσέγγιση, κατηγορικές (ποιοτικές μεταβλητές), καθώς οι αριθμοί δεν παίζουν κάποιο ρόλο, πέρα από την αναπαράσταση της εκάστοτε κατηγορίας.

Βλέπουμε τα αποτελέσματα του κώδικα:

```
ΑΠΟΤΕΛΕΣΜΑΤΑ CHI-SQUARE TEST ΑΝΕΞΑΡΤΗΣΙΑΣ
H0: Η προσέγγιση και το υπόβαθρο είναι ΑΝΕΞΑΡΤΗΤΑ
H1: Υπάρχει ΣΧΕΣΗ μεταξύ προσέγγισης και υποβάθρου

Βαθμοί ελευθερίας (df): 6  [(3-1)×(4-1)]
Στατιστικό χ²: 20.8929
Κριτική τιμή χ²(α=10%, df=6): 10.6446
p-value: 0.0019

ΣΥΜΠΕΡΑΣΜΑ
χ² = 20.8929 > χ²_κριτ = 10.6446
p = 0.0019 < α = 0.1
ΑΠΟΡΡΙΠΤΕΤΑΙ η H0.
Υπάρχει στατιστικά σημαντική σχέση (α=10%) ανάμεσα
  στην προσέγγιση διδασκαλίας και το υπόβαθρο του καθηγητή.

In [22]:
```

Εικόνα 6 Άσκηση 3

Εδώ, βάσει εκφώνησης, το επίπεδο α ισούται με 0,1. Η πιθανότητα είναι μικρότερη από το επίπεδο και ο X^2 είναι μεγαλύτερο από το χ^2_κριτ (το σημείο που το 90% της κατανομής βρίσκεται αριστερά), άρα η υπόθεση H_0 ΑΠΟΡΡΙΠΤΕΤΑΙ. Επομένως, υπάρχει στατιστική ένδειξη ότι η προσέγγιση της διδασκαλίας, σχετίζεται με το υπόβαθρο του καθηγητή.

Άσκηση 4/Διάλεξη 10:

Ομοίως, έγινε χρήση της Python και ο κώδικας είναι διαθέσιμος στο παράρτημα.

Από την εκφώνηση μπορούμε να δημιουργήσουμε τις υποθέσεις:

H_0: Η ανησυχία για βενζίνη είναι ίδια με την ανησυχία για ηλεκτρικό ρεύμα

H_1: Η ανησυχία για βενζίνη είναι μεγαλύτερη από την ανησυχία για ηλεκτρικό ρεύμα

Παρακάτω παρουσιάζονται τα αποτελέσματα του κώδικα:

```
Μέση ανησυχία βενζίνης:       3.113
Μέση ανησυχία για ρεύμα:     2.827

ΑΠΟΤΕΛΕΣΜΑΤΑ TEST
H0: Η ανησυχία για βενζίνη = ανησυχία για ρεύμα
H1: Η ανησυχία για βενζίνη > ανησυχία για ρεύμα

Στατιστικό W: 1548.5000
p-value (μονόπλευρος): 0.0006

ΣΥΜΠΕΡΑΣΜΑ
p = 0.0006 < α = 0.05
ΑΠΟΡΡΙΠΤΕΤΑΙ την H0.
Η ανησυχία για βενζίνη ήταν στατιστικά σημαντικά
  ΜΕΓΑΛΥΤΕΡΗ από την ανησυχία για ρεύμα (α=5%)
```

Εικόνα 7Άσκηση 4

Ο έλεγχος και εδώ είναι μονόπλευρος, καθώς εξετάζουμε μόνο για την αύξηση, όχι και για τις δύο κατευθύνσεις.

Παρατηρούμε ότι η πιθανότητα να είναι μικρότερη από το επίπεδο α = 0,05, επομένως η αρχική μας υπόθεση ΑΠΟΡΡΙΠΤΕΤΑΙ. Συνεπώς, από στατιστική άποψη, η ανησυχία για βενζίνη ήταν μεγαλύτερη από την ανησυχία για ρεύμα.

ΠΑΡΑΡΤΗΜΑ

Κώδικας Άσκησης 2:

```
import pandas as pd

import numpy as np

from scipy import stats


#Φόρτωση δεδομένων

df = pd.read_excel('Greek crisis.xlsx')

df.columns = ["This_Year", "Last_Year"]


print("ΔΕΔΟΜΕΝΑ")

print(df.describe().round(4))


#Υπολογισμός διαφορών d = Φέτος - Πέρσι

d = df["This_Year"] - df["Last_Year"]

n = len(d)

d_bar = d.mean()

s_d = d.std(ddof=1)


print(f"\nΑριθμός ζευγών (n): {n}")

print(f"Μέση διαφορά (d̄): {d_bar:.4f}")

print(f"Τυπική απόκλιση διαφορών (s_d): {s_d:.4f}")


#H0: μ_d = 0  (δεν υπάρχει αύξηση)

#H1: μ_d > 0  (οι λόγοι έχουν αυξηθεί)

t_stat, p_two_tailed = stats.ttest_rel(df["This_Year"], df["Last_Year"])
```

```
p_one_tailed = p_two_tailed / 2  # μονόπλευρος έλεγχος

# Κριτική τιμή t για α=5%, df=n-1, μονόπλευρος
alpha = 0.05
t_critical = stats.t.ppf(1 - alpha, df=n - 1)

#Εμφάνιση αποτελεσμάτων t-Test
print("\nΑΠΟΤΕΛΕΣΜΑΤΑ t-TEST\n")
print("Υπόθεση H0: μ_d = 0  (δεν υπάρχει αύξηση)")
print("Υπόθεση H1: μ_d > 0  (υπάρχει αύξηση)")
print(f"\nΒαθμοί ελευθερίας (df): {n - 1}")
print(f"Στατιστικό t: {t_stat:.4f}")
print(f"Κριτική τιμή t (α=5%, μονόπλευρος): {t_critical:.4f}")
print(f"p-value (μονόπλευρος): {p_one_tailed:.4f}")

#Εμφάνιση τελικού αποτελέσματος και απόρριψη/αποδοχή αρχικής υπόθεσης
print("\nΣΥΜΠΕΡΑΣΜΑ\n")
if t_stat > t_critical:
    print(f"t = {t_stat:.4f} > t_κριτ = {t_critical:.4f}")
    print(f"p = {p_one_tailed:.4f} < α = {alpha}")
    print("ΑΠΟΡΡΙΠΤΕΤΑΙ η H0.")
    print(" Υπάρχουν στατιστικά σημαντικές ενδείξεις (α=5%) ότι")
    print("  οι λόγοι χρέους/εισοδήματος έχουν ΑΥΞΗΘΕΙ.")
else:
    print(f"t = {t_stat:.4f} ≤ t_κριτ = {t_critical:.4f}")
    print(f"p = {p_one_tailed:.4f} ≥ α = {alpha}")
    print("ΔΕΝ απορρίπτεται η H0.")
    print("Δεν υπάρχουν επαρκείς στατιστικά ενδείξεις ότι οι λόγοι έχουν αυξηθεί.")
```

Κώδικας Άσκησης 3:

```
import pandas as pd
import numpy as np
from scipy import stats

#Φόρτωση δεδομένων
df = pd.read_excel('Statistics Books.xlsx')
df.columns = ["Προσέγγιση", "Υπόβαθρο"]

print("ΠΙΝΑΚΑΣ ΣΥΝΆΦΕΙΑΣ")
contingency = pd.crosstab(df["Προσέγγιση"], df["Υπόβαθρο"])
print(contingency)
print(f"\nΣύνολο παρατηρήσεων: {contingency.values.sum()}")

#Έλεγχος ανεξαρτησίας Χ^2
chi2, p_value, dof, expected = stats.chi2_contingency(contingency)



print("\nΑΝΑΜΕΝΌΜΕΝΕΣ ΣΥΧΝΟΤΗΤΕΣ")
expected_df = pd.DataFrame(
   expected,
   index=contingency.index,
   columns=contingency.columns
).round(2)
print(expected_df)

# Κριτική τιμή για α=10%
alpha = 0.10
chi2_critical = stats.chi2.ppf(1 - alpha, df=dof)
```

```
print("ΑΠΟΤΕΛΕΣΜΑΤΑ CHI-SQUARE TEST ΑΝΕΞΑΡΤΗΣΙΑΣ")
print("H0: Η προσέγγιση και το υπόβαθρο είναι ΑΝΕΞΑΡΤΗΤΑ")
print("H1: Υπάρχει ΣΧΕΣΗ μεταξύ προσέγγισης και υποβάθρου")
print(f"\nΒαθμοί ελευθερίας (df): {dof}  [(3-1)×(4-1)]")
print(f"Στατιστικό χ²: {chi2:.4f}")
print(f"Κριτική τιμή χ²(α=10%, df={dof}): {chi2_critical:.4f}")
print(f"p-value: {p_value:.4f}")


print("\nΣΥΜΠΕΡΑΣΜΑ")
if chi2 > chi2_critical:
    print(f"χ² = {chi2:.4f} > χ²_κριτ = {chi2_critical:.4f}")
    print(f"p = {p_value:.4f} < α = {alpha}")
    print("ΑΠΟΡΡΙΠΤΕΤΑΙ η H0.")
    print("Υπάρχει στατιστικά σημαντική σχέση (α=10%) ανάμεσα")
    print("  στην προσέγγιση διδασκαλίας και το υπόβαθρο του καθηγητή.")
else:
    print(f"χ² = {chi2:.4f} ≤ χ²_κριτ = {chi2_critical:.4f}")
    print(f"p = {p_value:.4f} ≥ α = {alpha}")
    print("ΔΕΝ απορρίπτεται την H0.")
    print("Δεν υπάρχουν επαρκείς ενδείξεις σχέσης μεταξύ")
    print("  προσέγγισης διδασκαλίας και υποβάθρου καθηγητή.")
```

Πασχαλίνα Κωνσταντινίδου, bad26014

Κώδικας Άσκησης 4:

```
import pandas as pd
import numpy as np
from scipy import stats

#Φόρτωση Δεδομένων
df = pd.read_excel('Gazoline vs electricity.xlsx')
df.columns = ["Βενζίνη", "Ρεύμα"]

print("ΠΕΡΙΓΡΑΦΙΚΑ ΣΤΑΤΙΣΤΙΚΑ")
print(df.describe().round(3))
print(f"\nΜέση ανησυχία βενζίνης:      {df['Βενζίνη'].mean():.3f}")
print(f"Μέση ανησυχία για ρεύμα:    {df['Ρεύμα'].mean():.3f}")

# H0: Οι κατανομές είναι ίδιες (διάμεσος διαφορών = 0)
# H1: Η ανησυχία για βενζίνη > ανησυχία για ρεύμα
stat, p_two_tailed = stats.wilcoxon(df["Βενζίνη"], df["Ρεύμα"],
                          alternative="two-sided")
_, p_one_tailed = stats.wilcoxon(df["Βενζίνη"], df["Ρεύμα"],
                        alternative="greater")

#Ορισμός α
alpha = 0.05

#Υποθέσεις
print("\nΑΠΟΤΕΛΕΣΜΑΤΑ TEST")
print("H0: Η ανησυχία για βενζίνη = ανησυχία για ρεύμα")
print("H1: Η ανησυχία για βενζίνη > ανησυχία για ρεύμα")
print(f"\nΣτατιστικό W: {stat:.4f}")
print(f"p-value (μονόπλευρος): {p_one_tailed:.4f}")
```

```
print("\nΣΥΜΠΕΡΑΣΜΑ")
if p_one_tailed < alpha:
    print(f"p = {p_one_tailed:.4f} < α = {alpha}")
    print("ΑΠΟΡΡΙΠΤΕΤΑΙ την H0.")
    print("Η ανησυχία για βενζίνη ήταν στατιστικά σημαντικά")
    print("  ΜΕΓΑΛΥΤΕΡΗ από την ανησυχία για ρεύμα (α=5%).")
else:
    print(f"p = {p_one_tailed:.4f} ≥ α = {alpha}")
    print("ΔΕΝ απορρίπτεται την H0.")
    print("Δεν υπάρχουν επαρκείς ενδείξεις ότι η ανησυχία")
    print("  για βενζίνη ήταν μεγαλύτερη από αυτή για ρεύμα.")
```